LinkUp · 2 차 프로젝트 결과 발표

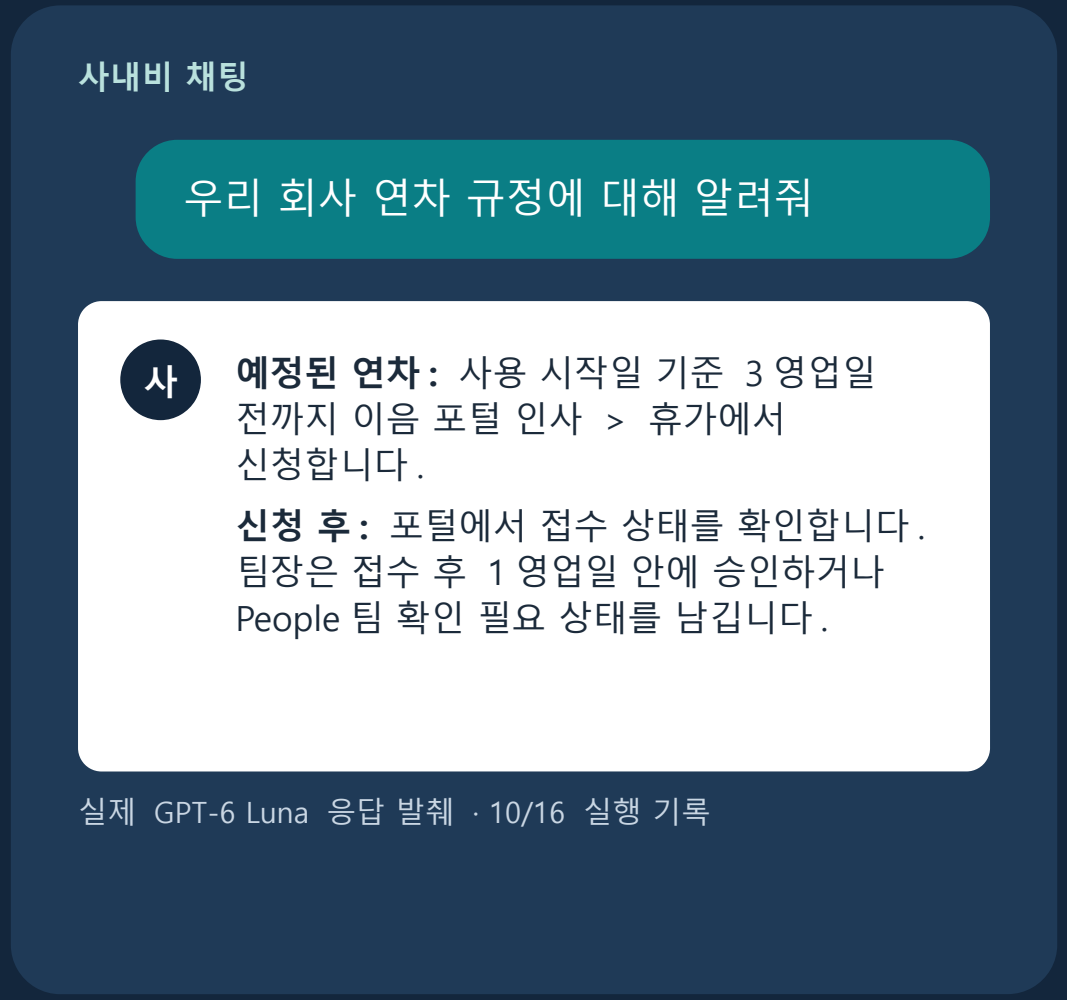
사내비

회사 규정이 궁금할 때,
질문으로 시작하는 업무 도우미

발표 최재선 · LinkUp 팀

가상 회사 이음웍스의 서비스 출시를 콘셉트로 구성

2026.10.16



사내비를 만든 이유

회사에 자료가 있어도, 내 질문에 필요한 답을 찾는 과정은 남아 있습니다

“연차 신청은 어느 문서에서 확인하죠?”

1. **문서 위치 찾기**
   어느 자료가 기준인지
   먼저 찾아야 합니다
2. **조건과 절차 읽기**
   신청 기한과 경로를
   문서에서 골라 읽습니다
3. **담당자에게 다시 묻기**
   내 상황에 맞는지
   다시 확인합니다

사내비의 목표

- ✓ **질문 하나로 시작**
- ✓ **회사 문서에 근거한 안내**
- ✓ **할 수 없는 일은 분명하게**

사내비가 돕는 일

회사 문서에서 질문에 필요한 안내를 찾아 정리합니다

우리 회사 연차 규정에 대해 알려줘

사

예정된 연차 : 사용 시작일 기준 3 영업일 전까지 이음 포털 인사 > 휴가에서 신청합니다 . ...

갑작스러운 사정 : ... 근무 시작 전에 팀장에게 Slack 으로 알리고 , 여건이 되는 가장 빠른 시점에 포털 신청을 보완합니다 .

신청 후 : 포털에서 접수 상태를 확인합니다 . 팀장은 접수 후 1 영업일 안에 승인하거나 People 팀 확인 필요 상태를 남깁니다 . ...

이 안내만으로는 법령상 연차 부여 일수나 개인별 잔여 일수를 계산할 수 없습니다 . ...

실제 응답 발췌 · 개발 중 실행 기록 · '...' 는 생략

휴가 · 근태 | 비용 · 정산 | IT· 보안

사내비가 하는 일

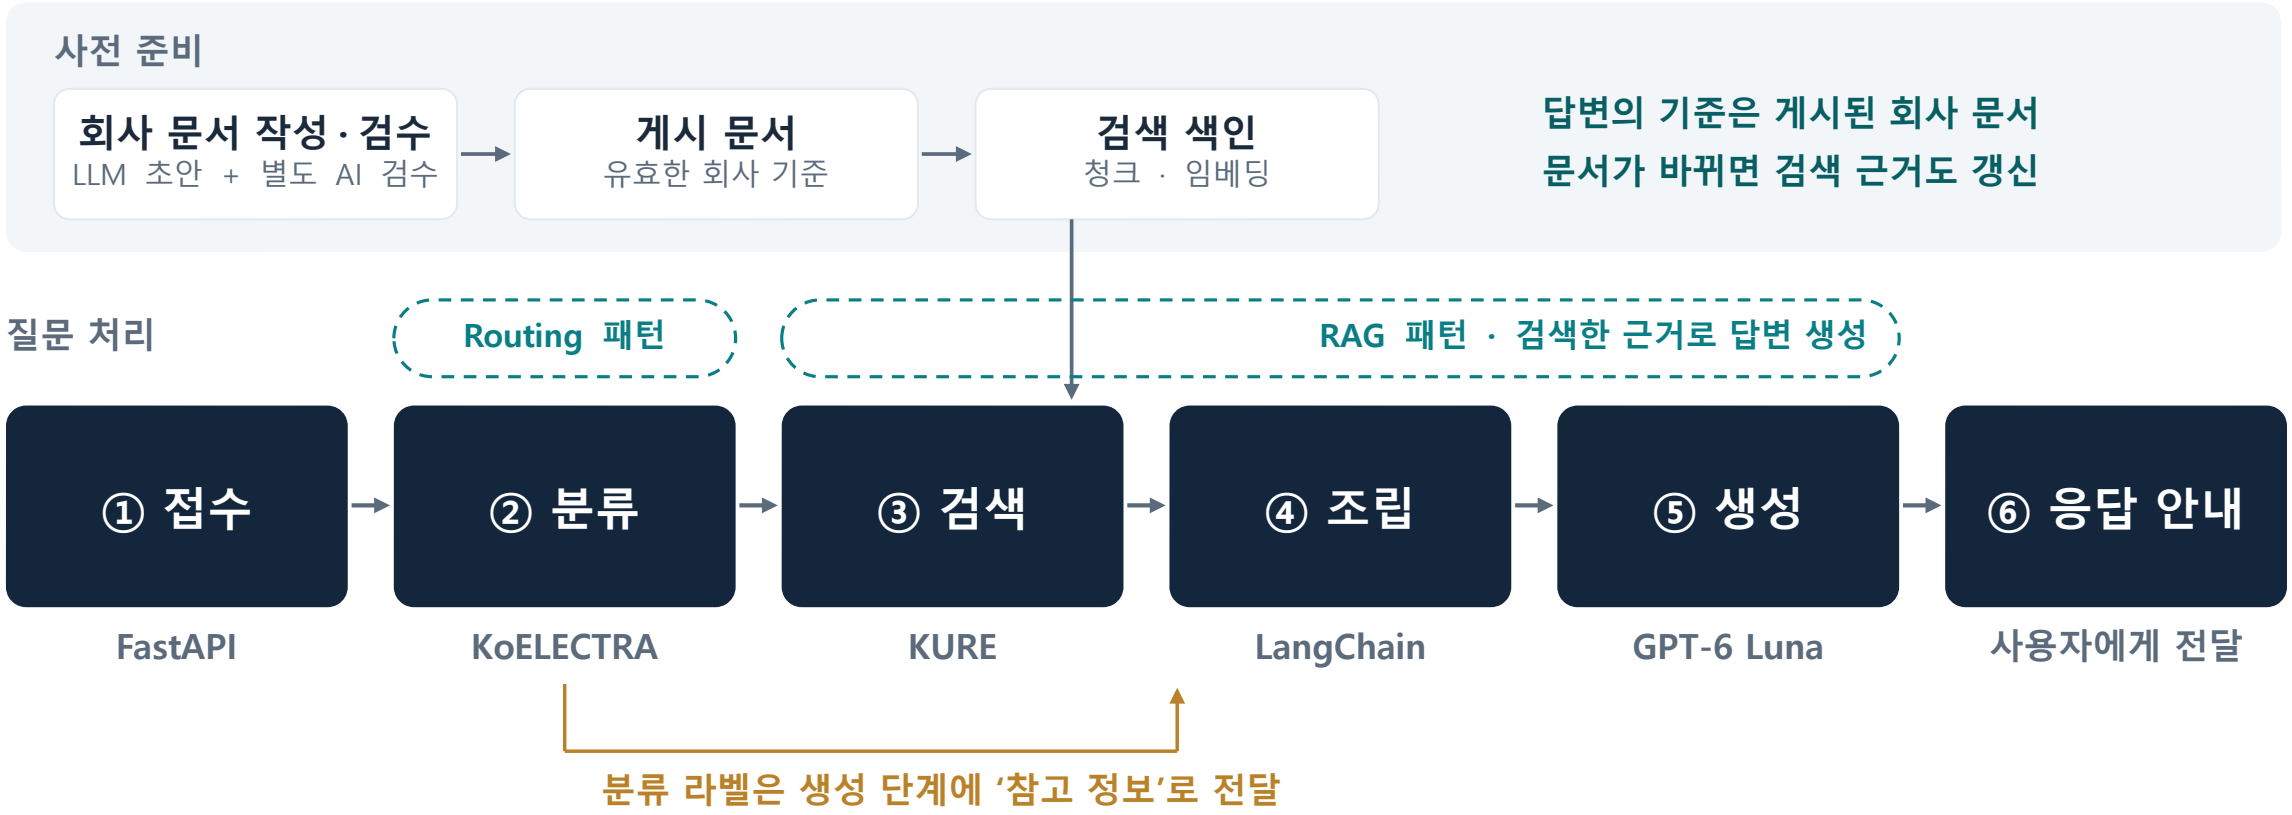
- ✓ 규정 · 절차를 문서 근거로 안내
- ✓ 기한 · 경로 · 담당 역할 정리
- ✓ 자료 부족과 지원 범위 설명

하지 않는 일

- × 개인 잔여 일수 조회
- × 신청 · 승인 대행

질문에서 답변까지, 사내비의 흐름

문서를 미리 준비하고, 질문마다 필요한 근거를 찾아 답변으로 연결합니다



답변의 기준이 될 회사 문서 준비

규정의 내용뿐 아니라 대상 · 절차 · 예외 · 담당 역할이 일관되도록

01
공개 자료
공개 회사 핸드북
국내 공식 안내

→

02
회사 설정
역할 · 도구
신청 절차

→

03
LLM 작성
출처와 설정을
반영한 초안

→

04
별도 AI 검수
조건 누락 · 충돌
수정 후 재검수

→

05
71 개 문서
고정 ID 와
출처 · 개정 기록

각 문서가 답해야 할 다섯 가지

누구에게 적용되는가 | 무엇을 하는가 | 예외는 무엇인가 | 누가 맡는가 | 무엇을 확인하는가

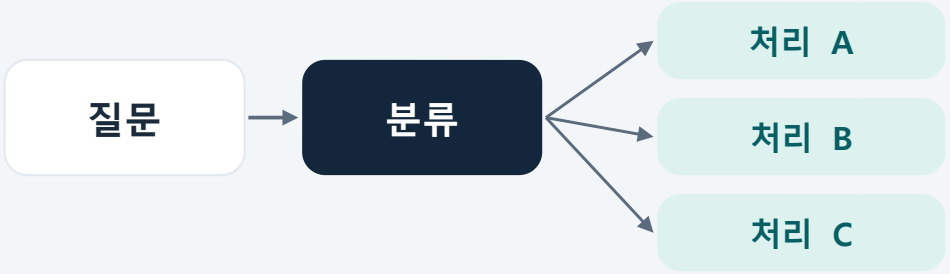
52 개 초기 문서 → 19 개 업무 안내 추가 · 기존 본문 보강 → 총 71 개

외부 자료의 절차 구성과 이음웍스의 도구 · 기한 · 담당 역할을 구분해 작성

질문 분류 : Routing 패턴을 참고했습니다

요청을 먼저 분류해, 각각에 맞는 후속 처리로 보내는 설계

Routing 패턴이란



서로 다르게 처리할 범주가 있고 분류를 정확하게 할 수 있을 때 적합

분류는 LLM 뿐 아니라 전통적인 분류 모델로도 가능

Anthropic "Building Effective Agents" · LangChain 공식 예제

초기에 구상한 세 가지 처리 방향

SEARCH_KNOWLEDGE
회사 문서로 안내할 정보 요청
→ 문서 근거로 안내

CLARIFY
대상이나 의도가 불분명한 요청
→ 구체적으로 되묻기

UNSUPPORTED
범위 밖 정보 · 조회 · 실행 요청
→ 지원 범위 안내

공개 자료에서 확인한 구성 Google 질의 분류, AWS·NVIDIA 주제 가드레일처럼 입력 판단을 답변 생성과 별도 단계로 둔다

세 질문 유형은 사내비가 정한 기준 · 실험을 거쳐 분류 결과를 활용하는 방식을 조정

분류 결과의 역할을 조정했습니다

분류 결과로 답변을 사전 차단했을 때 생긴 문제와 바꾼 방식

1 강제 차단

**분류가 범위 밖이면
고정 안내로 종료**

'우리 회사 연차 규정에 대해 알려줘'를 범위 밖으로 예측
→ 답변 자체가 막힘

두 번 모두 통과 25/40

→

2 관찰만

**분류는 기록만 하고
모든 질문을 문서로 안내**

같은 연차 질문 4 응답 모두 통과
그러나 분류가 서비스에
영향을 주지 않음

두 번 모두 통과 30/40

→

3 참고 전달 · 현재

**분류 결과를 오류 가능한
참고 정보로 생성에 전달**

원질문과 문서를 우선
연차 질문이 범위 밖으로
오분류돼도 정상 안내

10/16 실행 확인

작은 비교에서 품질 향상은 확인되지 않음 → 분류 결과를 생성에 반영한다는 설계 의도로 채택

1·2 는 40 문항 × 2 회, 당시 전체 문서 입력 조건 · 연차 질문 2 종 × 2 회 = 4 응답 · 3 은 10/16 질문 서비스 경로 진단 실행

질문을 준비하고, 분류 모델을 비교했습니다

회사 문서 71 개는 답변 근거 · 질문 900 개는 요청 유형을 학습하고 평가할 자료

모델	검증 F1	test F1	CPU ms/ 질문
TF-IDF + LR (베이스라인)	0.9550	0.9778	0.32
BERT base	0.9852	0.9851	20.20
RoBERTa base	1.0000	0.9629	18.60
KoELECTRA base	**0.9851**	**0.9851**	**17.91**

KoELECTRA: test 133/135 정답 · CPU 17.91 ms

검증 점수뿐 아니라 test 결과 · 지연 · 오분류를 함께 보고 선택

1 질문 작성 · 라벨 검수

AI 로 작성 · 독립 검수
세 질문 유형별 300 개

↓

2 유사 상황을 묶어 분할

표현을 바꾼 질문이
학습 · 평가에 나뉘지 않도록

↓

3 같은 자료로 학습 · 비교

TF-IDF 기준선 +
사전학습 모델 5 종 미세조정

F1 = Macro-F1 · 학습 632 / 검증 133 / test 135 · 합성 질문의 개발 평가 결과 · 전체 후보 · 실행 조건은 부록 A1

근거 검색 : 전체 문서 입력에서 RAG 로

처음에는 문서 전체를 넣었고, 한계를 확인한 뒤 필요한 근거만 찾아 넣는 방식으로 바꿨습니다

처음 : 문서 71 건을 모두 입력

왜 시작했나 지식 집합이 작으면 전체를 프롬프트에 넣는 방식도 가능 (Anthropic, Contextual Retrieval)

부딪힌 문제

- ! 약 67k 토큰 → 초기 문맥 설정 40,960 초과
- ! 설정 확대 후에도 긴 입력의 처리 부담
- ! 관련 정보의 위치에 따라 성능 차이
  참고 연구 : Lost in the Middle

지금 : RAG · 검색한 근거로 답변 생성

1. **질문 임베딩**
   질문을 벡터로 변환
2. **관련 구간 검색**
   KURE 로 유사도 비교 · 상위 20 구간
3. **원문 문맥 구성**
   겹친 구간 병합 · 주변 절 보충
4. **생성에 전달**
   원질문과 근거를 함께 전달

RAG = Retrieval-Augmented Generation · 질문과 관련된 문서를 검색해 답변의 근거로 활용

검색 모델을 선택한 과정

신규 확인 40 문항 · 필요한 근거의 유지와 전달량을 함께 비교

문항당 평균 전달 문자



약 82%

Tiny C 대비 전달 문자 감소
평가 25 문항의 필수 근거 유지

필수 근거 완전 포함

25 / 25

두 구성 동일

관련 질문 잘못 차단

0 / 30

두 구성 동일

무관 질문 차단

4 / 10

목표 5/10 미달

후속 문맥 보충 관련 문서를 찾아도 필요한 절이 빠지는 문제 → 관련 절을 함께 전달

Tiny C = KoEn-E5-Tiny 기반 검색 구성 · 82% 는 후속 문맥 보충 전 고정 검색 평가의 전달 문자 수 비교

찾은 근거를 답변으로 연결

LangChain 으로 질문 · 문서 · 참고 정보를 묶어, 문서에 근거한 답변을 요청



문서는 답변의 근거, 공통 규칙은 답변의 방향 · 참고 : Microsoft RAG 프롬프트 설계 안내

답변 모델을 선택한 과정

모델 선정 당시 · 전체 71 문서 입력 · 같은 20 문항 × 2 회

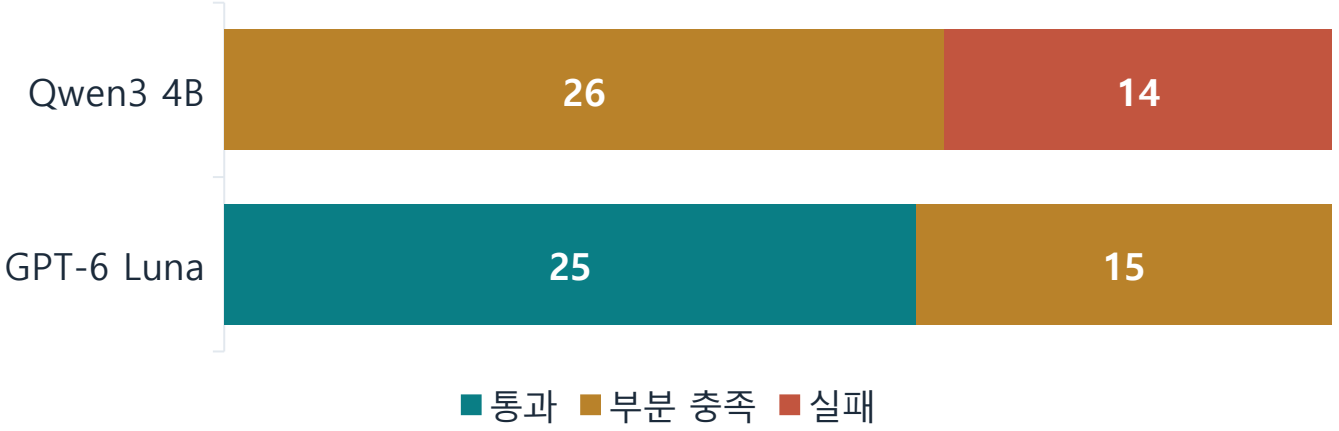
Local · Qwen3 4B

노트북 GPU 8GB · Ollama

Cloud · GPT-6 Luna

상용 API

응답 40 개 판정 (통과 / 부분 충족 / 실패)



두 번 모두 통과

Qwen **0 / 20**

Luna **11 / 20**

응답 시간 중앙값

Qwen **32.80 초**

Luna **12.09 초**

40 회 API 비용

Qwen **과금 없음 ***

Luna **약 $0.173**

평가 기준 문서와 맞는가 · 필요한 안내를 담았는가 · 없는 내용을 덧붙이지 않았는가

모델명을 가린 AI 판정 · Luna 도 두 번 모두 통과 목표 18/20 에는 미달 · 당시 실행 설정·비용 산정은 부록 A4

실제 답변에서 확인한 차이

"신규 입사자가 사원증과 사무실 출입 권한을 받으려면 어떤 신청 절차가 필요한가요?"

문서의 발급 순서 — People 팀이 총무 요청 → 총무 담당자가 본인에게 카드 발급

GPT-6 Luna

통과

"재직 상태와 근무 장소가 확인되면 People 팀이 포털에서 총무 요청을 만들고, 총무 담당자가 신입사원 본인에게 카드를 발급합니다."

문서의 주체와 순서를 반영

Qwen3 4B

실패

"사원증은 입사 후 팀장과 People 팀의 확인을 거쳐 발급되며, 사무실 출입 권한은 팀장이 승인한 계정에 따라 발급됩니다."

문서에 없는 승인 관계를 추가

답변 원문 일부 발췌 · 문서 ieum-013 기준 · 생성 모델 선정 비교의 실제 응답 (반복 1) · 전체 응답은 노트의 출처

LIVE DEMO

사내비 사용 시연

배포 서비스에서 업무 질문과 지원 범위를 확인합니다

01

“우리 회사 연차 규정에 대해 알려줘”

신청 기한 · 경로 · 신청 후 확인할 내용

02

“세그먼트 트리에 대해 설명해줘”

회사 업무와 관계없는 질문의 지원 범위 안내

sanaebi.29232923.xyz/chat

공용 가상 문서 · 매일 자정 초기화

시연이 지연되면 개발 중 확인한 실제 응답 사례로 설명 · 부록 A6

프로젝트 결과와 다음 개선

문서 기반 안내를 구현하며, 분류·검색·생성에서 각각 다른 문제를 확인했습니다

구현한 기능

1. 회사 문서에서 업무 절차 안내
2. 신청 조건 · 담당 역할 · 확인 사항
3. 자료 부족과 지원 범위 설명

다음으로 개선할 것

1. 새 질문과 사람 검수로 평가 확대
2. 필수 절차와 조건의 누락 점검
3. 검색 근거가 답에 충분한지 확인

만들면서 배운 점

1. 정상 질문의 차단을 보고 분류를 참고 정보로 조정
2. 문서를 찾는 것과 필요한 절을 전달하는 것은 다르다
3. 자연스러운 답변도 문서의 주체·조건과 대조

합성 자료와 AI 평가로 확인한 개발 결과 · 실제 사용자 질문과 사람 검수로 평가 확대 필요

함께 만든 사내비

분류·API·LangChain을 나누어 맡고, 연결 과정에서 함께 점검했습니다

최

최재선

총괄 · 데이터·분류 · 프로젝트 전반

학습·비교, 개발·통합, 검증과 제출 조율

유

유원호

생성 모델 비교 · 답변 평가

LangChain 협업, 로컬·상용 비교와 디버깅

윤

윤승환

FastAPI · 요청·응답 연결

기능 연결, 정상·실패 처리 검증

전

전항록

문서 검색 · 프롬프트·응답 처리

LangChain 협업과 검색·생성 흐름 연결

협업 방식 회의·개인 일지 · Slack 논의 · Notion 결정 기록 · GitHub 브랜치·PR 통합

팀 역할 분담과 사용자 확인 기준 · 개발·실험·문서화에 AI 도구 활용

회사 규정이 궁금할 때,
사내비에 질문하세요.

감사합니다. 질문과 의견을 듣겠습니다.

sanaebi.29232923.xyz/chat

프로젝트 코드 · 실험 기록

github.com/KANT-2nd-project/sanaebi

공개 데모는 가상 문서를 사용합니다. 실제 사내 자료나 개인정보는 입력하지 마세요.

분류 모델 전체 결과와 학습 조건

동일 그룹 분할의 개발 결과 · API 후보의 실행 조건은 별도

모델	검증 F1	test F1	평균 ms/ 질문
TF-IDF + LR	0.9550	0.9778	0.32
RoBERTa small	0.9775	0.9778	10.29
KoELECTRA small	0.9850	0.9556	4.43
BERT base	0.9852	0.9851	20.20
RoBERTa base	1.0000	0.9629	18.60
KoELECTRA base	**0.9851**	**0.9851**	**17.91**
Jev API *	0.9693	0.9625	194.50

학습 632 / 검증 133 / test 135 · seed 20261013 · Transformer 최대 256 토큰 · batch 4 · TF-IDF 문자 2–5gram · C 0.1/0.5/1/10

* Jev 는 예시 12 개를 넣은 API 평가 · HTTP 시간을 CPU 추론 시간과 직접 순위 비교하지 않음

분류의 역할이 바뀐 과정

분류 라벨은 근거 존재나 응답 품질을 보장하지 않습니다

단계	의도와 관측	설계에 반영한 점
초기 Routing	유형을 나누어 후속 처리 결정	세 라벨은 서비스 자체의 기준
강제 차단 비교	정상 연차 질문이 차단됨	원질문과 문서 확인을 우선
관찰만	분류 결과를 기록만 함	생성 프롬프트에는 미전달
현재 참고 전달	**공통 지침과 서버 예측 라벨 전달**	**오류 가능한 참고 정보로 사용**

KURE 소규모 A/C 비교 : 4/5 대 3/5 · 다른 주제 3/5 대 4/5

일관된 품질 우위는 확인하지 못했으며, 분류를 참고시키는 설계 의도로 채택

A = 라벨 미전달 · C = 공통 지침 + 라벨 · 작은 합성 자료·AI 판정 · 라벨 없는 공통 지침 대조군 없음

검색 비교와 후속 문맥 보충

같은 원문을 사용했지만, 모델과 검색 정책이 함께 다른 구성 비교

항목	이전 검색 구성 (Tiny C)	KURE
공통 자료	71 문서 · 298 청크	같은 원문 구간 사용
분할	360 토큰 · 중첩 60	고정 Tiny tokenizer 사용
선택 기준	개별 cosine ≥ 0.35	최고 cosine ≥ 0.4288
전달 구간	하한 이상 청크	병합 전 상위 20 청크
신규 확인 40 문항	근거 25 + 관련 답없음 5 + 무관 10	관련 오차단 0/30 · 무관 차단 4/10

후속 문맥 보충: 중요한 절 복원 관측 → 초기 보류 → 사용자 결정으로 적용

문맥 보충 설정: 최대 3 문서 · 추가 6,000 자

문맥 보충은 각 조건 1 회 진단 (유효 JSON 7 · 파싱 실패 1) · 결합 구성의 반복 품질 미검증 · 앞선 82% 를 재측정한 결과가 아님

생성 비교 조건과 비용

71 개 전체 문서를 사용한 당시 비교 · 현재 RAG 전체 품질·비용과 구분

항목	Qwen3 4B Q4_K_M	GPT-6 Luna
입력·평가	71 문서 · 20 문항 × 2 회	같은 자료·질문 · AI 판정
실행 설정	출력 1,024 · 문맥 98,304	출력 4,096 · reasoning xhigh
추가 조건	temperature 0 · seed 42	temperature 미전달
실행 환경	GPU 35/37 층 · 초기 자원 경합	상용 API · 네트워크 포함
중앙값 / 최대	32.80 / 161.46 초	12.09 / 26.81 초
40 회 비용	장비·전력 미산정	사용량 추정 약 $0.173

Luna 보수적 예산 추정 약 $0.337 · 두 추정 모두 당시 요율 기준이며 실제 청구액이 아님 · 안정 통과 11/20 은 목표 18/20 미달

후속 RAG 서비스 구성 : reasoning xhigh · 출력 한도 16,384 (위 비교와 다른 설정)

참고한 설계와 문서의 출처

외부 자료, 회사 고유 결정, 실제 실험 기록을 구분했습니다

설계	출처	사내비에 적용한 점
Routing	Anthropic "Building Effective Agents" · LangChain Workflows	질문 분류 단계 · 처리가 다른 요청을 먼저 나눔
전체 문서 입력	Anthropic "Contextual Retrieval"	작은 지식 집합은 전체 입력 가능 → 초기 설계
긴 입력의 한계	Liu et al. "Lost in the Middle" (TACL 2024)	정보 위치에 따른 성능 차이 → RAG 전환 근거
RAG · 근거 한정	Microsoft RAG 안내 · Azure·AWS·NVIDIA 공개 참조	근거와 지침 분리 · 검색 → 근거 한정 생성
문서 작성	GitLab·PostHog 공개 핸드북 · 국내 공식 자료	가상 회사 결정 → LLM 작성 → 별도 AI 검수

외부 자료는 설계의 출처이며 서비스 성능의 입증 자료가 아님 · 세 라벨이나 문서 작성 과정을 기업 공통 표준으로 소개하지 않음

참고 : 개발 중 실제 응답 사례

10/16 실행 기록 · 질문당 1 회 · AI 판정

“우리 회사 연차 규정에 대해 알려줘”

분류가 범위 밖으로 예측했지만 문서 기준으로 안내

예정된 연차 : 사용 시작일 기준 3 영업일 전까지 이음 포털 인사 > 휴가에서 신청합니다 . … 신청 후 : 포털에서 접수 상태를 확인합니다 . 팀장은 접수 후 1 영업일 안에 승인하거나 People 팀 확인 필요 상태를 남깁니다 . …

“세그먼트 트리에 대해 설명해줘”

업무와 무관한 질문에 서비스의 지원 범위를 안내

사내비는 이음웍스의 사내 업무 정보와 절차를 안내하는 서비스라 , 세그먼트 트리 같은 일반 지식 설명은 도와드리기 어렵습니다 . 회사 업무나 시스템에서 세그먼트 트리를 어떻게 사용하는지 궁금하신 경우에는 그 맥락을 알려 주세요 .

두 사례 모두 개발 중 실행 기록이며 현재 배포 화면의 녹화가 아님 · 서로 다른 실행 조건은 노트에 명시 · ‘…’ 는 생략